

LAPORAN TEKNIS DATA SCIENCE

Sistem Rekomendasi Skill dan Karir Berbasis AI

CC26-PSU331 Coding Camp 2026 powered by DBS Foundation

Tim Data Scientist :

- Giga Syakir Ihsan Syahbani (CDCC329D6Y0622)
- Zurich Sabil (CDCC329D6Y0598)

1. PENDAHULUAN

1.1 Latar Belakang Masalah

Perkembangan dunia kerja saat ini berlangsung sangat cepat. Kemunculan teknologi baru menyebabkan kebutuhan keterampilan di pasar kerja terus berubah. Banyak mahasiswa maupun pencari kerja mengalami kesulitan dalam menentukan pekerjaan yang sesuai dengan kemampuan yang mereka miliki.

Sebagai contoh, seseorang yang menguasai Python dan SQL belum tentu mengetahui bahwa kombinasi skill tersebut relevan untuk posisi seperti Data Analyst atau Data Engineer. Di sisi lain, banyak pencari kerja merasa kesulitan karena lowongan pekerjaan sering kali membutuhkan lebih banyak skill dibanding yang mereka kuasai saat ini.

Permasalahan tersebut dikenal sebagai *skill mismatch*, yaitu ketidaksesuaian antara keterampilan individu dengan kebutuhan industri. Kondisi ini berdampak pada meningkatnya kesulitan perusahaan dalam mencari kandidat yang sesuai, sekaligus menyulitkan pencari kerja memperoleh pekerjaan. Sebagian besar platform pencarian kerja saat ini hanya menampilkan informasi lowongan tanpa memberikan arahan mengenai skill yang perlu dipelajari pengguna. Oleh karena itu, dibutuhkan sistem yang mampu memberikan rekomendasi pekerjaan sekaligus rekomendasi pengembangan skill secara personal.

Untuk menjawab permasalahan tersebut, tim mengembangkan sistem rekomendasi berbasis Artificial Intelligence yang mampu:

- merekomendasikan pekerjaan sesuai skill pengguna,
- menganalisis kesenjangan skill (*skill gap*),
- memberikan rekomendasi skill yang perlu dipelajari.

1.2 Problem Statement

Bagaimana membantu individu menemukan pekerjaan yang sesuai dengan skill yang dimiliki serta memberikan rekomendasi skill yang perlu dipelajari untuk meningkatkan peluang karir?

1.3 Research Questions

1. Bagaimana memetakan skill pengguna ke pekerjaan yang relevan secara otomatis?
2. Bagaimana sistem mengidentifikasi skill gap dan memberikan rekomendasi belajar?
3. Seberapa akurat model dalam memberikan rekomendasi pekerjaan dan skill?

1.4 Solusi yang Dikembangkan

Sistem rekomendasi dibangun menggunakan pendekatan *content-based filtering* dengan tahapan sebagai berikut:

1. Normalisasi Input Skill Pengguna

Input pengguna seperti:

Python, SQL, Machine Learning diubah menjadi format terstruktur: `['python', 'sql', 'machine learning']`

Seluruh teks diubah menjadi huruf kecil dan dibersihkan dari spasi berlebih.

2. Konversi Skill Menjadi Vektor Numerik

Skill pengguna dan skill pada dataset dikonversi menjadi representasi numerik menggunakan metode **TF-IDF Vectorizer**.

3. Perhitungan Kemiripan

Kemiripan antara skill pengguna dan skill setiap pekerjaan dihitung menggunakan Cosine Similarity dengan rentang nilai 0–1.

4. Rekomendasi Pekerjaan

Seluruh pekerjaan diurutkan berdasarkan nilai similarity tertinggi, kemudian sistem menampilkan pekerjaan paling relevan.

5. Analisis Skill Gap

Skill pengguna dibandingkan dengan skill yang dibutuhkan pekerjaan untuk mengetahui skill yang belum dikuasai.

2. DATA WRANGLING

2.1 Gathering Data

Dataset yang digunakan bernama *all_job_post.csv* dengan total 1.167 data lowongan pekerjaan.

Dataset memiliki lima kolom utama:

- *job_id*
- *category*
- *job_title*
- *job_description*
- *job_skill_set*

Kolom `job_skill_set` menjadi fokus utama karena berisi daftar skill yang dibutuhkan setiap pekerjaan.

2.2 Assessing Data

Pemeriksaan kualitas data dilakukan untuk memastikan dataset layak digunakan

Kriteria Pemeriksaan	Hasil / Kondisi
Jumlah Baris	1.167
Nilai Null / Missing Value	0 (Bersih)
Data Duplikat	0 (Tidak ada)
Tipe Data <code>job_id</code>	Integer
Tipe Data Kolom Lainnya	String / Object

Distribusi Kategori Pekerjaan

Berikut adalah persebaran jumlah data berdasarkan kategori pekerjaan yang tersedia di dalam dataset

Kategori	Jumlah Lowongan
Information Technology	240
Business Development	239
Finance	236
Sales	232
HR	220

Insight: Distribusi kategori dalam dataset ini relatif merata sehingga tidak terdapat dominasi ekstrem pada satu kategori tertentu (balanced dataset).

2.3 Cleaning Data

Proses pembersihan data dilakukan melalui beberapa tahapan transformasi text:

1. Standardisasi Teks : Mengubah seluruh teks menjadi huruf kecil (*lowercase*).
2. Menghapus Spasi Berlebih: Menghapus spasi ganda atau tidak beraturan agar format teks konsisten.
3. Perbaikan Format Kategori: Mengubah tanda hubung pada nama kategori menjadi spasi biasa.
 - Contoh: *INFORMATION-TECHNOLOGY* menjadi *information technology*
 - Contoh: *BUSINESS-DEVELOPMENT* menjadi *business development*
4. Membersihkan Deskripsi Pekerjaan: Karakter khusus, baris baru (*newline \n*), dan simbol-simbol non-alfanumerik yang tidak diperlukan dihapus dari kolom deskripsi.
5. Parsing Skill List: Kolom `job_skill_set` awalnya bertipe string biasa dan diubah menjadi bentuk objek list Python menggunakan fungsi `ast.literal_eval()`.
 - Sebelum: `"['Python', 'SQL']"` (String)
 - Sesudah: `['python', 'sql']` (List)
6. Ekstraksi Fitur Baru: Menambahkan kolom baru bernama `num_skills` untuk menghitung total jumlah skill yang tertera pada setiap lowongan pekerjaan.

3. Data Dictionary

No	Nama Kolom	Tipe Data	Deskripsi
1	<i>job_id</i>	Integer	ID unik untuk setiap lowongan pekerjaan
2	<i>category</i>	String	Kategori atau bidang industri pekerjaan
3	<i>job_title</i>	String	Nama posisi atau jabatan pekerjaan
4	<i>job_description</i>	String	Deskripsi lengkap mengenai tanggung jawab pekerjaan
5	<i>job_skill_set</i>	String	Daftar skill yang dibutuhkan (format string awal)
6	<i>job_skill_set_parsed</i>	List	Daftar skill yang sudah dikonversi ke format List Python
7	<i>num_skills</i>	Integer	Total jumlah skill yang dibutuhkan pada pekerjaan tersebut

Statistik Deskriptif *num_skills*

Analisis statistik dasar untuk kolom *num_skills* menunjukkan metrik sebagai berikut:

- Rata-rata (Mean) : 17,85 skill per pekerjaan
- Nilai Minimum : 5 skill
- Nilai Maksimum : 43 skill

4. EXPLORATORY DATA ANALYSIS (EDA)

4.1 Distribusi Jumlah Skill

Berdasarkan visualisasi data, rata-rata setiap lowongan pekerjaan membutuhkan sekitar 18 skill. Sebagian besar distribusi lowongan pekerjaan menumpuk pada rentang 10 hingga 25 skill.

4.2 Kategori dengan Lowongan Terbanyak

Kategori Information Technology menempati posisi teratas dengan total 240 lowongan, disusul ketat oleh Business Development (239) dan Finance (236).

4.3 Posisi Pekerjaan Terbanyak (Top Job Titles)

Beberapa posisi spesifik yang paling sering muncul dalam dataset ini antara lain:

- Business Development Manager: 53 lowongan
- Human Resources Generalist: 34 lowongan
- Business Development Representative: 33 lowongan
- Human Resources Manager: 29 lowongan

4.4 Skill yang Paling Banyak Diminta (Global Top Skills)

Dari total keseluruhan data lowongan, berikut adalah skill yang paling dicari oleh perusahaan

Skill	Jumlah Lowongan Terkait
Communication	1.092
Problem Solving	878
Adaptability	588
Teamwork	569
Collaboration	341

Insight: Mayoritas skill teratas merupakan **soft skills**. Hal ini membuktikan bahwa industri tidak hanya menitikberatkan pada kemampuan teknis (*hard skills*), melainkan juga pada aspek komunikasi dan kemampuan berkolaborasi di dalam tim.

4.5 Analisis Kategori HR (Human Resources)

Total lowongan khusus untuk kategori HR berjumlah 220 pekerjaan. Adapun urutan skill yang paling mendominasi di kategori ini adalah:

1. *Communication* (207 lowongan)
2. *Problem Solving* (171 lowongan)
3. *Employee Relations* (102 lowongan)
4. *Adaptability* (102 lowongan)

4.6 Analisis Kategori Information Technology (IT)

Total lowongan untuk kategori IT berjumlah 240 pekerjaan. Berbeda dengan HR, kebutuhan manajemen proyek mulai krusial di bidang ini:

1. *Communication* (219 lowongan)
2. *Problem Solving* (191 lowongan)
3. *Adaptability* (112 lowongan)
4. *Project Management* (84 lowongan)

5. FEATURE ENGINEERING

5.1 Kombinasi Fitur (Feature Combination)

Untuk memperkaya konteks pemahaman model terhadap karakteristik lowongan, beberapa kolom tekstual digabungkan menjadi satu kesatuan fitur utama

combined_features = *category* + " " + *job_title* + " " + *job_description* + " " + *job_skill_set*

5.2 Text Preprocessing (NLP Pipeline)

Guna mereduksi noise pada teks hasil penggabungan, diterapkan tahapan pemrosesan teks berupa:

- Mengubah teks menjadi huruf kecil (*case folding/lowercase*).
- Menghapus angka dan karakter tanda baca (*punctuation*).
- Memecah kalimat menjadi token kata (*tokenizing*).
- Menghapus kata umum yang kurang bermakna (*stopword removal*).
- Mengubah kata ke bentuk kata dasarnya (*stemming* menggunakan PorterStemmer).

Contoh Hasil Preprocessing:

- **Input:** "A Human Resources Manager needs strong leadership and problem solving skills"
- **Output:** "human resourc manag need strong leadership problem solv skill"

5.3 TF-IDF Vectorization

Teks yang telah bersih ditransformasikan ke dalam representasi matriks numerik menggunakan teknik **Term Frequency - Inverse Document Frequency (TF-IDF)**.

- Parameter yang digunakan: `max_features = 5000`
- Hasil akhir ekstraksi berupa matriks berdimensi: **1.167 baris x 5.000 kolom**

5.4 Cosine Similarity

Kemiripan antar lowongan maupun kemiripan input pengguna dengan lowongan dihitung menggunakan formula Cosine Similarity. Nilai akhir berada pada rentang [0, 1] di mana nilai 1 merepresentasikan kemiripan mutlak dan nilai 0 menunjukkan tidak adanya kemiripan sama sekali. Matriks similarity yang dihasilkan memiliki dimensi **1.167 x 1.167**.

5.5 Export Model

Model beserta komponen pendukung diexport ke dalam bentuk file *binary .pkl* agar siap digunakan pada tahap *deployment* aplikasi:

Nama File	Isi / Komponen
<i>tfidf_matrix.pkl</i>	Matriks hasil pembobotan TF-IDF dataset
<i>cosine_similarity.pkl</i>	Matriks nilai kedekatan/kemiripan antar data
<i>tfidf_vectorizer.pkl</i>	Objek model fit TF-IDF Vectorizer

6. A/B TESTING & EVALUASI MODEL

Eksperimen dilakukan untuk membandingkan dua pendekatan performa model rekomendasi:

6.1 Model A. Baseline

Model ini hanya menggunakan arsitektur preprocessing teks mendasar tanpa mengaplikasikan *stopword removal* dan proses *stemming*.

- **Hasil:** Rata-rata nilai *cosine similarity* sebesar **0.2527**.

6.2 Model B. Preprocessing Lengkap

Model ini mengimplementasikan keseluruhan *pipeline* NLP secara penuh (termasuk eliminasi *stopwords* dan *stemming*).

- **Hasil:** Rata-rata nilai *cosine similarity* sebesar **0.1136**.

6.3 Komparasi Hasil Rekomendasi Kasus HR

Saat dilakukan uji coba input profil karir HR, berikut perbandingan hasil rekomendasi teratas

Peringkat	Rekomendasi Model A (Baseline)	Rekomendasi Model B (Full Preprocessing)
1	Human Resources Director	Human Resources Manager
2	Human Resources Generalist	Human Resources Director
3	Human Resources Manager	Human Resources Generalist

6.4 Interpretasi Hasil Evaluasi

Meskipun secara angka numerik Model A mencatatkan nilai kedekatan (*similarity score*) yang lebih tinggi, **Model B terbukti menghasilkan rekomendasi yang jauh lebih relevan secara kontekstual**. Hal ini terjadi karena Model B berhasil membuang kata hubung bawaan yang tidak esensial (*stopwords*) sehingga kalkulasi kesamaan murni didasarkan pada kata kunci penting dan *core skills*.

Keputusan Akhir: Model B dipilih sebagai model final yang diintegrasikan ke sistem produksi.

7. DASHBOARD STREAMLIT

7.1 Fitur Dashboard

Aplikasi web interaktif dibangun menggunakan Streamlit dengan fungsionalitas utama sebagai berikut:

Nama Fitur	Fungsi Utama
Input Skill	Menyediakan kolom bagi pengguna untuk memasukkan daftar keahlian yang mereka miliki saat ini.
Rekomendasi Pekerjaan	Menampilkan daftar lowongan pekerjaan yang paling cocok diurutkan berdasarkan skor kemiripan tertinggi.
Skill Gap Analysis	Menganalisis perbedaan serta menampilkan list skill spesifik yang belum dikuasai pengguna dari pekerjaan yang direkomendasikan.
Visualisasi Data	Menampilkan grafik tren rekrutmen dan insight pasar kerja interaktif bagi pengguna.

7.2 Alur Cara Kerja Aplikasi

[User Input Skill] —> [Text Preprocessing] —> [Kalkulasi Cosine Similarity] —> [Tampilan Rekomendasi & Skill Gap]

7.3 Deployment

Aplikasi dashboard ini telah sukses dideploy melalui infrastruktur cloud platform dan siap diakses oleh publik.

Link Dashboard: <https://dashboard-skillmatchai.streamlit.app/>

8. KESIMPULAN

1. Sistem rekomendasi kecocokan skill dan karir berbasis AI berhasil dikembangkan menggunakan kombinasi metode pembobotan **TF-IDF Vectorizer** dan pengukuran **Cosine Similarity**.
2. Berdasarkan fase EDA, ditemukan fakta bahwa *soft skills* memegang peranan krusial di dunia industri kerja saat ini. Keterampilan seperti *communication* dan *problem solving* senantiasa muncul secara konsisten di hampir seluruh kategori industri pekerjaan.
3. Melalui pengujian A/B Testing, pendekatan *pipeline text preprocessing* yang lengkap (Model B) divalidasi memberikan hasil penentuan rekomendasi posisi yang jauh lebih akurat dan relevan dibandingkan model baseline (Model A).
4. Aplikasi dashboard berbasis Streamlit berjalan dengan optimal dan sukses bertindak sebagai instrumen bantu bagi kandidat pencari kerja untuk memetakan jalur karir serta mengidentifikasi ketertinggalan *skill gap* mereka.

